



이상치 탐지 성능 향상을 위한 MI-FGSM 데이터 증강 기법

장현석¹, 정민성¹, 이충호², 허태욱² *이상금¹

*국립한밭대학교¹, 한국전자통신연구원²



논문 바로가기

EcoAI Lab

Abstract

- (기후문제 및 이상치 탐지 필요성) 화공 산업은 국내 온실가스 배출의 상당 부분을 차지하며, 효과적인 온실가스 배출량 감축과 기후변화 대응을 위해 신뢰성 높은 전력 데이터 분석과 이상치 탐지가 필수적임.
- (클래스 불균형) 데이터 분석 결과, 정상 데이터 대비 이상치가 적은 클래스 불균형이 존재하였고 이는 탐지 결과의 신뢰성을 저해함.
- (데이터 증강 적용) 학습 데이터를 MI-FGSM에 적용해 생성된 적대적 샘플을 통해 이상치를 증강하고 두 클래스간 균형을 조절함.
- (성능 분석) MI-FGSM 파라미터인 최대 교란 크기 ϵ 과 모델의 탐지 성능 지표인 F1 점수간 상관관계를 분석함.
- (ϵ 임계값 도출) ϵ 과 F1 점수의 상관관계 그래프를 통해 F1 점수의 성능이 낮아지는 ϵ 의 임계값을 도출하고 데이터 증강을 위한 MI-FGSM의 ϵ 허용 범위에 대한 가이드라인을 제시함.

Introduction & Research Background




그림1. 산업부문 내 업종별 온실가스 배출 비율

- (그림1) 산업 부문 내 제조업 99.6%, 광업 0.4%로 제조업이 매우 큰 비중을 점유함.

- (그림2) 제조업 중 금속, 화학, 정유, 기타 제조업이 총 95.9%를 차지하며, 그 중 화학 산업이 29.2%를 차지함.




그림2. 제조업 내 업종별 온실가스 배출 비율

LSTM-AE & MI-FGSM

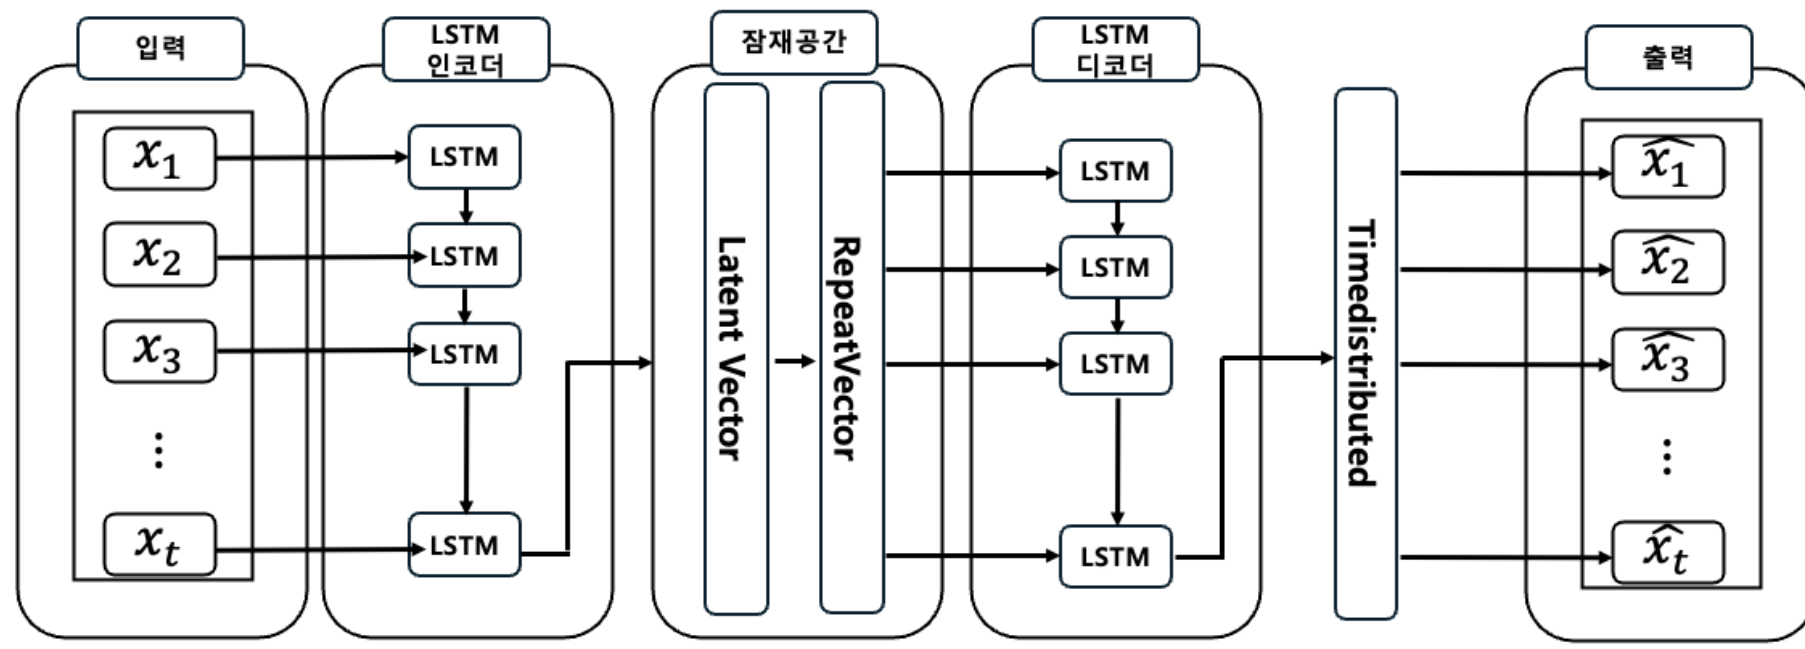


그림3. LSTM-AE 모델 구조

- (그림3) LSTM(Long Short - Term Memory)과 AE(AutoEncoder)의 결합 모델인 LSTM-AE 구조도이며, 각 층의 역할은 다음과 같음.
- (LSTM 인코더/디코더) 시계열 데이터의 시간 의존성을 반영하여 데이터 포인트를 순차적으로 처리함.
- (잠재공간) 인코더에서 데이터의 핵심 정보를 벡터 형태로 변환하고, RepeatVector에서 디코더의 입력 형태로 변환함.
- (MI-FGSM) 생성된 적대적 샘플을 통해 데이터 형태와 동일하게 변환함.

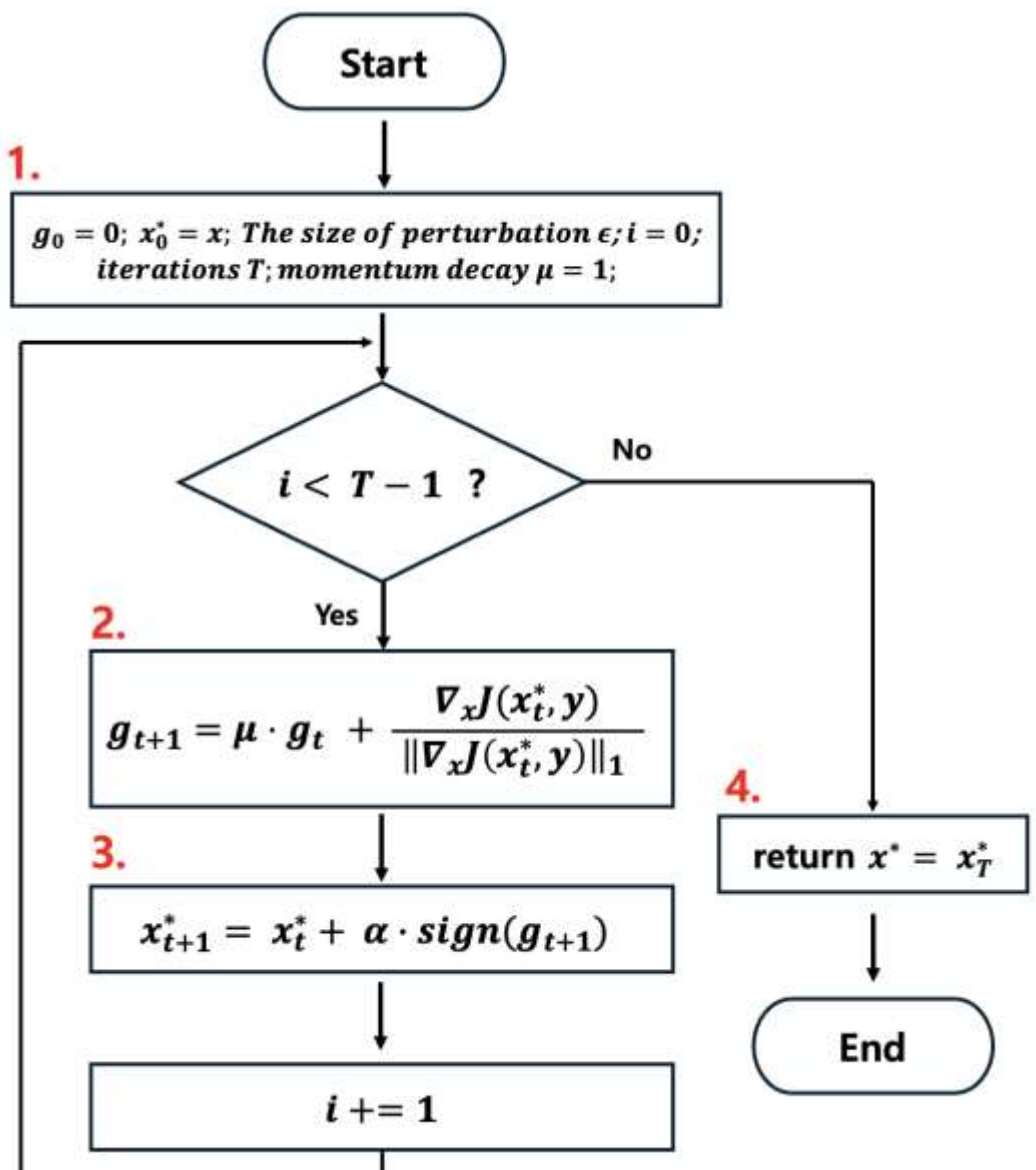


그림4. MI-FGSM 알고리즘 흐름도

- (1단계) 모멘텀 벡터 g_0 와 적대적 샘플 x_0^* , 교란 크기 ϵ , 반복 횟수 T , 모멘텀 계수 μ , 카운터 i 선언함.
- (2단계) 시점 t 의 모멘텀에 μ 를 곱한 값과 비용 함수 J 의 적대적 샘플 x_t^* 와 정답 레이블 y 에 대한 입력 데이터 x 의 그래디언트 방향 성분을 더해 $t+1$ 시점의 모멘텀 g_{t+1} 을 구함.
- (3단계) 시점 t 의 적대적 샘플 x_t^* 에 g_{t+1} 의 방향으로 α 만큼 이동한 값을 더해 $t+1$ 시점의 적대적 샘플 x_{t+1}^* 을 생성함.
- 2,3 단계를 카운터의 조건 만족 시까지 반복함
- (4단계) T 번의 업데이트 과정으로 갱신된 적대적 샘플 x_T^* 을 반환.

실험 및 결과

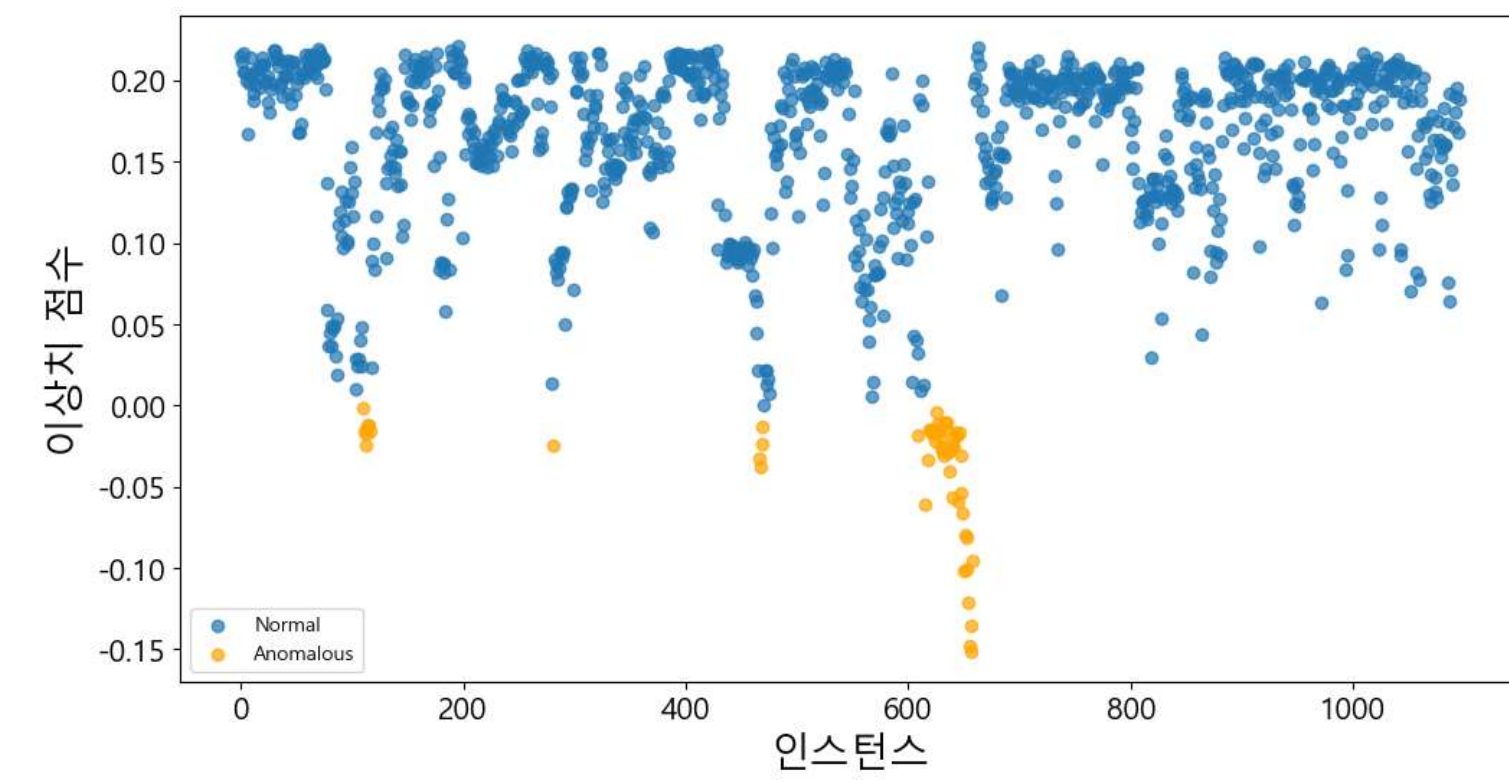


그림5. Isolation Forest 이상치 분류 결과

- (데이터셋)(그림5) 2020년 1월부터 2022년 12월까지 15분 단위로 수집된 전력 데이터 중 점유율이 높은 기업의 데이터를 사용함. Isolation Forest 분류 결과, 전체 1096개의 데이터 중 55개의 이상치가 존재함.

- (전처리)데이터를 [0, 1]로 정규화하고, 이상치 증강을 위해 학습 데이터를 MI-FGSM에 적용해 적대적 샘플을 생성함. 이를 활용해 테스트셋의 클래스 불균형을 완화함. 이때 ϵ 은 재구성 오차의 임계값과 탐지 성능에 영향을 미쳐, 정규화된 데이터 스케일에 따라 ϵ 을 미세한 범위인 [0.5, 0.25, 0.1, 0.05, 0.01]에서 조정하며 탐지 결과를 비교함.




그림6. 이상치 탐지 재구성 오차 분포($\epsilon = 0.5$)




그림7. 이상치 탐지 재구성 오차 분포($\epsilon = 0.01$)

- (그림6) $\epsilon = 0.5$ 일 때 MI-FGSM으로 생성된 적대적 샘플은 대부분 재구성 오차의 임계값보다 큼. 기존 이상치 대비 정상 데이터에 근사한 분포를 보이며, F1 점수는 0.9778로 높은 성능이 나옴.
- (그림7) $\epsilon = 0.01$ 일 때의 재구성 오차는 그림 6와 달리, 적대적 샘플의 분포가 임계값과 현저하게 높은 유사성을 보임. 또한, F1 점수는 0.6907로 $\epsilon = 0.5$ 일 때 대비 0.2871이 감소함.




그림8. ϵ 와 F1 점수의 상관관계 그래프

- (그림8) 빨간색 점에 해당하는 $\epsilon = 0.25$ 지점부터 ϵ 값이 작아짐에 따라 F1 점수가 낮아지며, 0에 수렴할수록 급격하게 감소함. ϵ 이 크면 노이즈의 교란 범위가 넓어져 이상치 탐지가 용이하지만, ϵ 이 작아질수록 교란 범위가 좁아져 정상 데이터와의 구분 경계가 모호해짐. 따라서, F1 점수가 낮아지는 시작점인 $\epsilon = 0.25$ 를 실험 데이터의 임계값으로 선정함.

결론

- (연구 목표) 화공 산업 전력 데이터의 클래스 불균형을 해소하고, LSTM-AE의 이상치 탐지 성능에 대한 신뢰성을 향상하고자 MI-FGSM 기반 데이터 증강 방법론을 제안함.
- (실험 과정) 화공 산업 내 점유율이 높은 기업 데이터를 전처리 후, $\epsilon = [0.5, 0.25, 0.1, 0.05, 0.01]$ 범위에서 F1점수를 비교함.
- (실험 결과) $\epsilon = 0.5$ 에서 0.9778의 F1 점수를 달성한 반면, ϵ 이 감소됨에 따라 F1 점수가 낮아지는 경향을 보였고, $\epsilon = 0.01$ 에서는 F1 점수는 0.6907임.
- (시사점) ϵ 과 F1 점수의 상관관계를 분석한 결과, ϵ 이 임계값보다 낮아 교란 범위가 과도하게 좁을 경우 적대적 샘플과 정상 데이터간 구분이 불분명하여 탐지 성능이 저하됨.

향후 연구

- (일반화 검증) 다양한 데이터셋에서 MI-FGSM 기반 데이터 증강을 적용해 일반화를 검토할 필요가 있음.
- (적대적 학습 적용) 적대적 학습과 이상치 탐지 과정을 하나의 파이프라인으로 통합하는 End-to-End 구조로 탐지 성능을 최적화하고자 함.
- (산업체별 특성 기반 최적화) 다양한 산업체의 고유한 특성에 적합하도록 모델을 조정·적용하여, 산업체의 적용가능성 및 운영 효율 향상에 기여함.