



# 고속 푸리에 변환(FFT) 기반 주기 추출 및 윈도우 구성을 활용한 GELU CNN-GRU AE 모델의 산업 전력 시계열 이상치 탐지

박범도<sup>1</sup>, 권우현<sup>1</sup>, 이충호, 허태욱<sup>2</sup>, \*이상금<sup>1</sup>


\*국립한밭대학교<sup>1</sup>, 한국전자통신연구원<sup>2</sup>



## Abstract

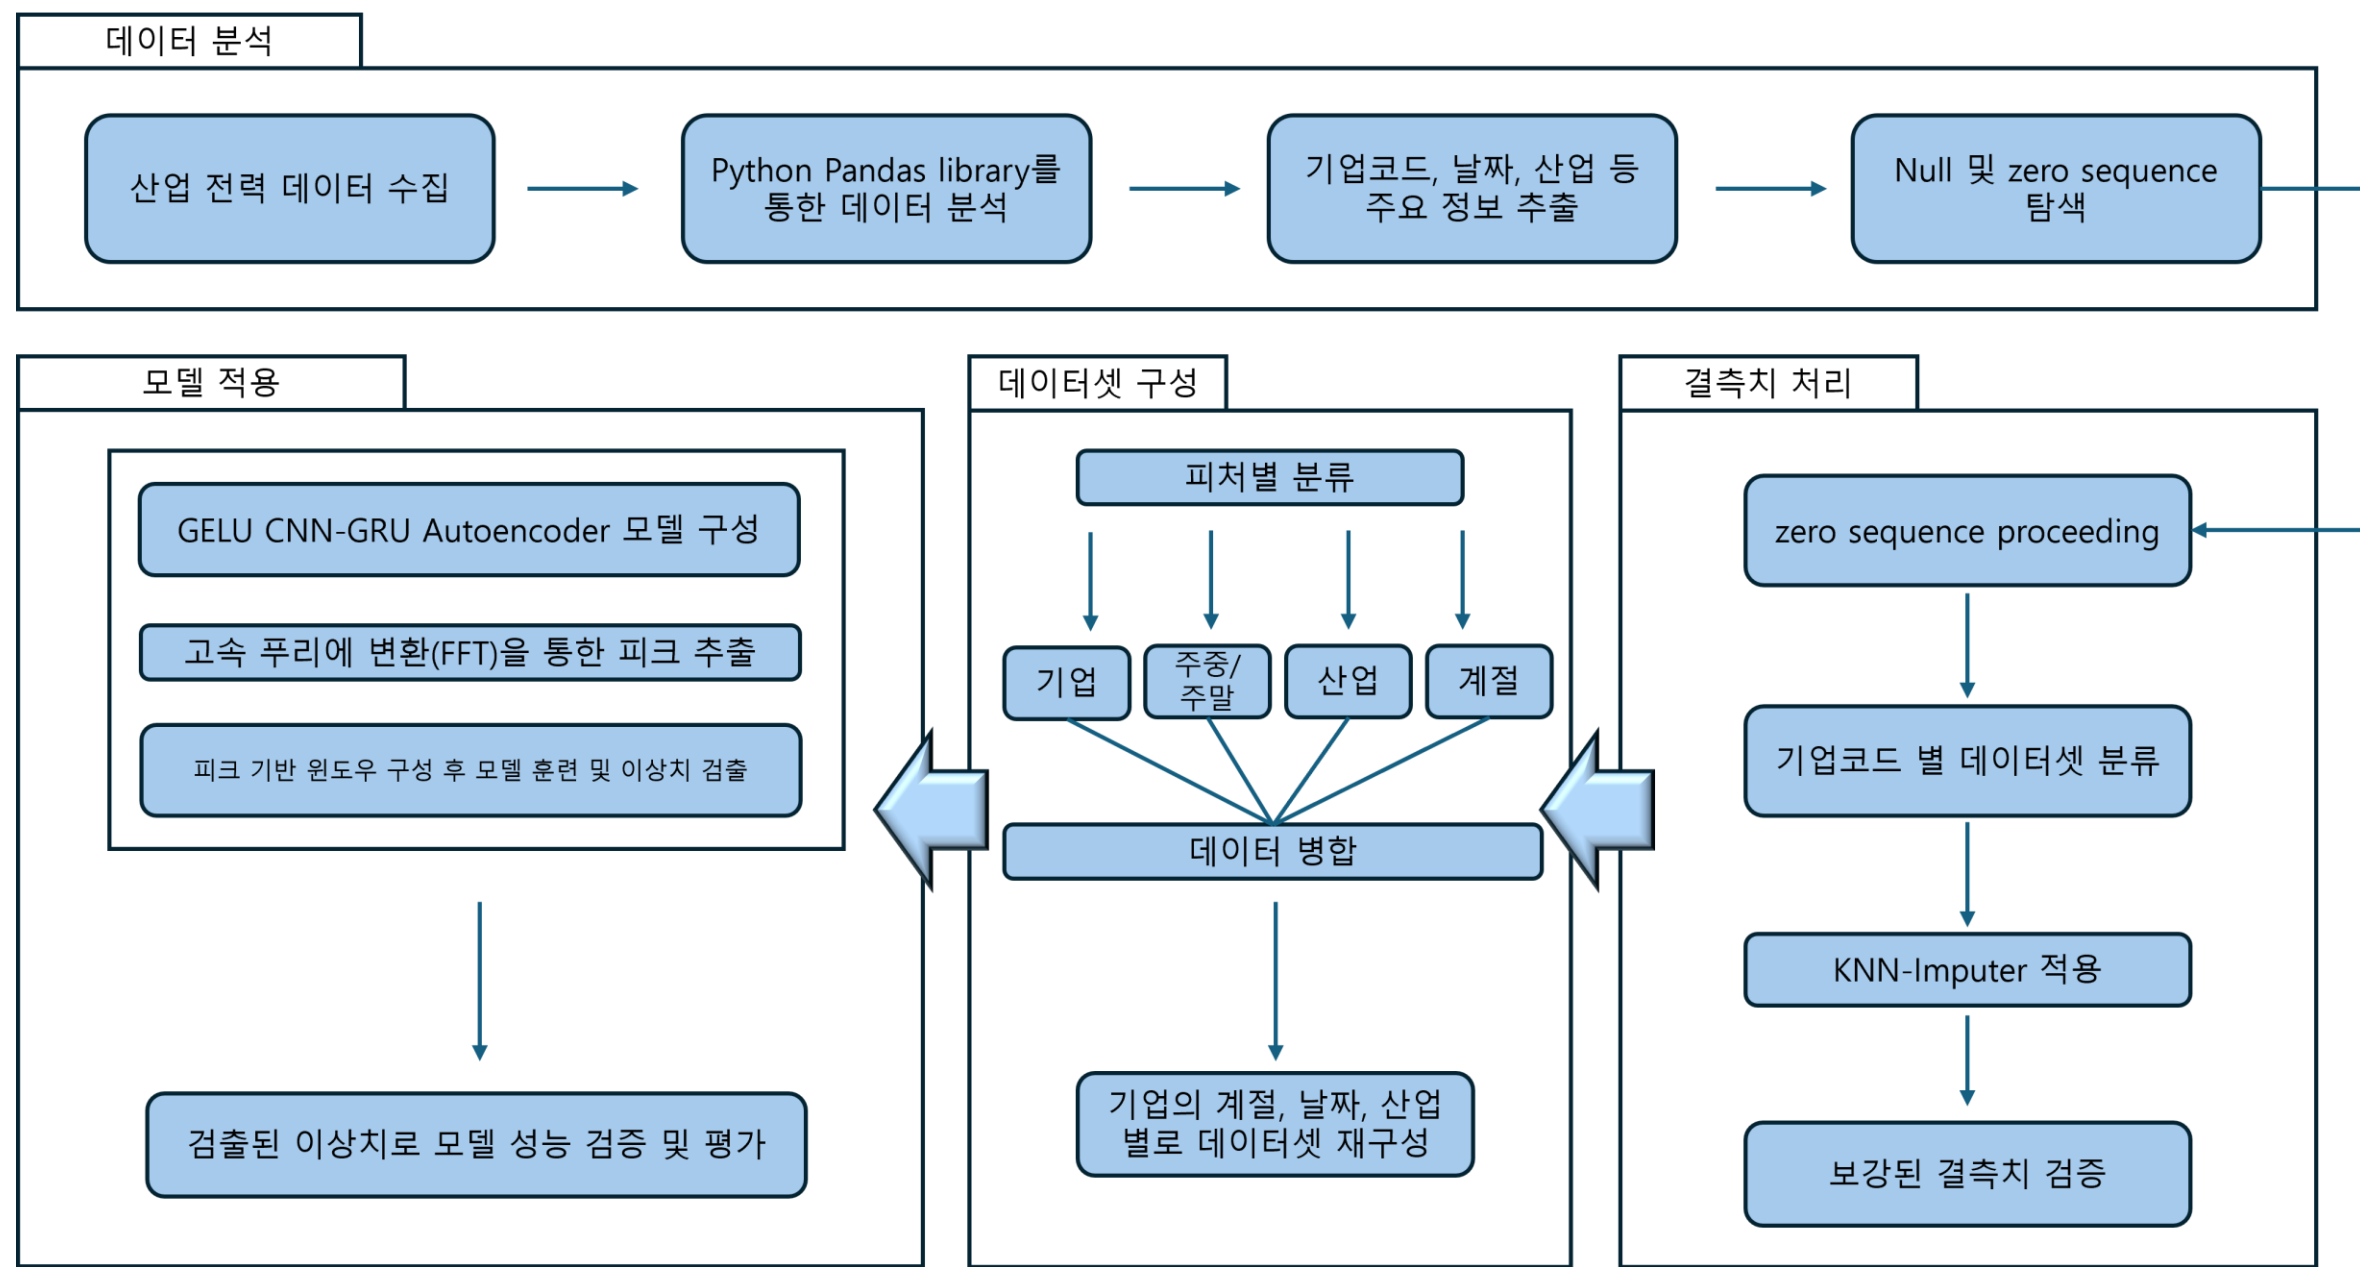
- (연구 배경 및 목표) 산업 현장의 복잡한 전력 데이터로부터 설비 고장 예방 및 에너지 효율 최적화를 목표로, FFT 기반의 동적 윈도우 구성과 GELU CNN-GRU 오토인코더를 결합한 이상치 탐지 방법론을 제안
- (데이터 전처리 및 주기 추출) 1차 차분으로 데이터의 변화 패턴을 강조하고, FFT 분석으로 주요 주파수 성분을 식별하여 상위 주기를 객관적으로 추출, 이를 동적 분석 윈도우로 설정
- (다중 윈도우 기반 이상 탐지 모델) 추출된 주기들로 다중 스케일 윈도우를 구성, CNN으로 지역적 패턴을, GRU로 시간적 의존성을 학습하는 오토인코더 모델을 설계. GELU 활성화 함수로 학습 안정성을 확보
- (DTW 및 Isolation Forest 기반 이상치 판별) 시간 축 왜곡에 강인한 오차 측정을 위해 DTW를 활용하고, 계산된 오차 점수 분포에 비지도 학습인 Isolation Forest를 적용하여 이상치 윈도우를 최종 판별
- (연구 의의) 제안된 다단계 방식은 실제 산업 현장의 다양한 이상 상황에 정교하게 대응 가능하며, 스마트 팩토리의 데이터 기반 예지 보전 시스템 구축을 위한 핵심 기술로 활용될 수 있음

## Introduction & Research Background



산업 설비의 예지보전과 에너지 관리 효율화, 시스템 안정성 확보를 위해서는 전력 데이터의 이상 탐지가 필수적이다. 기존의 통계적 방법은 복잡한 이상 패턴을 포착하는 데 한계가 있으며, 딥러닝 기반 Autoencoder 구조가 이상 탐지의 효과적인 대안으로 주목받고 있다. 본 연구는 FFT 기반 다중 주기 분석, CNN-GRU Autoencoder, DTW, Isolation Forest 등을 통합하여, 실제 산업 환경에서 다양한 시간 스케일의 이상 상황을 신뢰성 있게 탐지하는 방안을 제시한다.

## Objective



## Materials & Methods

### 데이터 전처리

- 데이터셋: (2020~2022년) 3년간 15분 단위로 수집된 특정 산업체의 전력 사용량 데이터
- 결측치 처리: sklearn.KNN Imputer를 이용, 시계열 데이터 패턴 고려 및 연속성 확보
- 1차 차분 (Differencing): 비정상성을 완화하고 급격한 변화를 강조하여 동적 윈도우 구성에 활용

### FFT 기반 주기 추출 & 동적 윈도우 구성

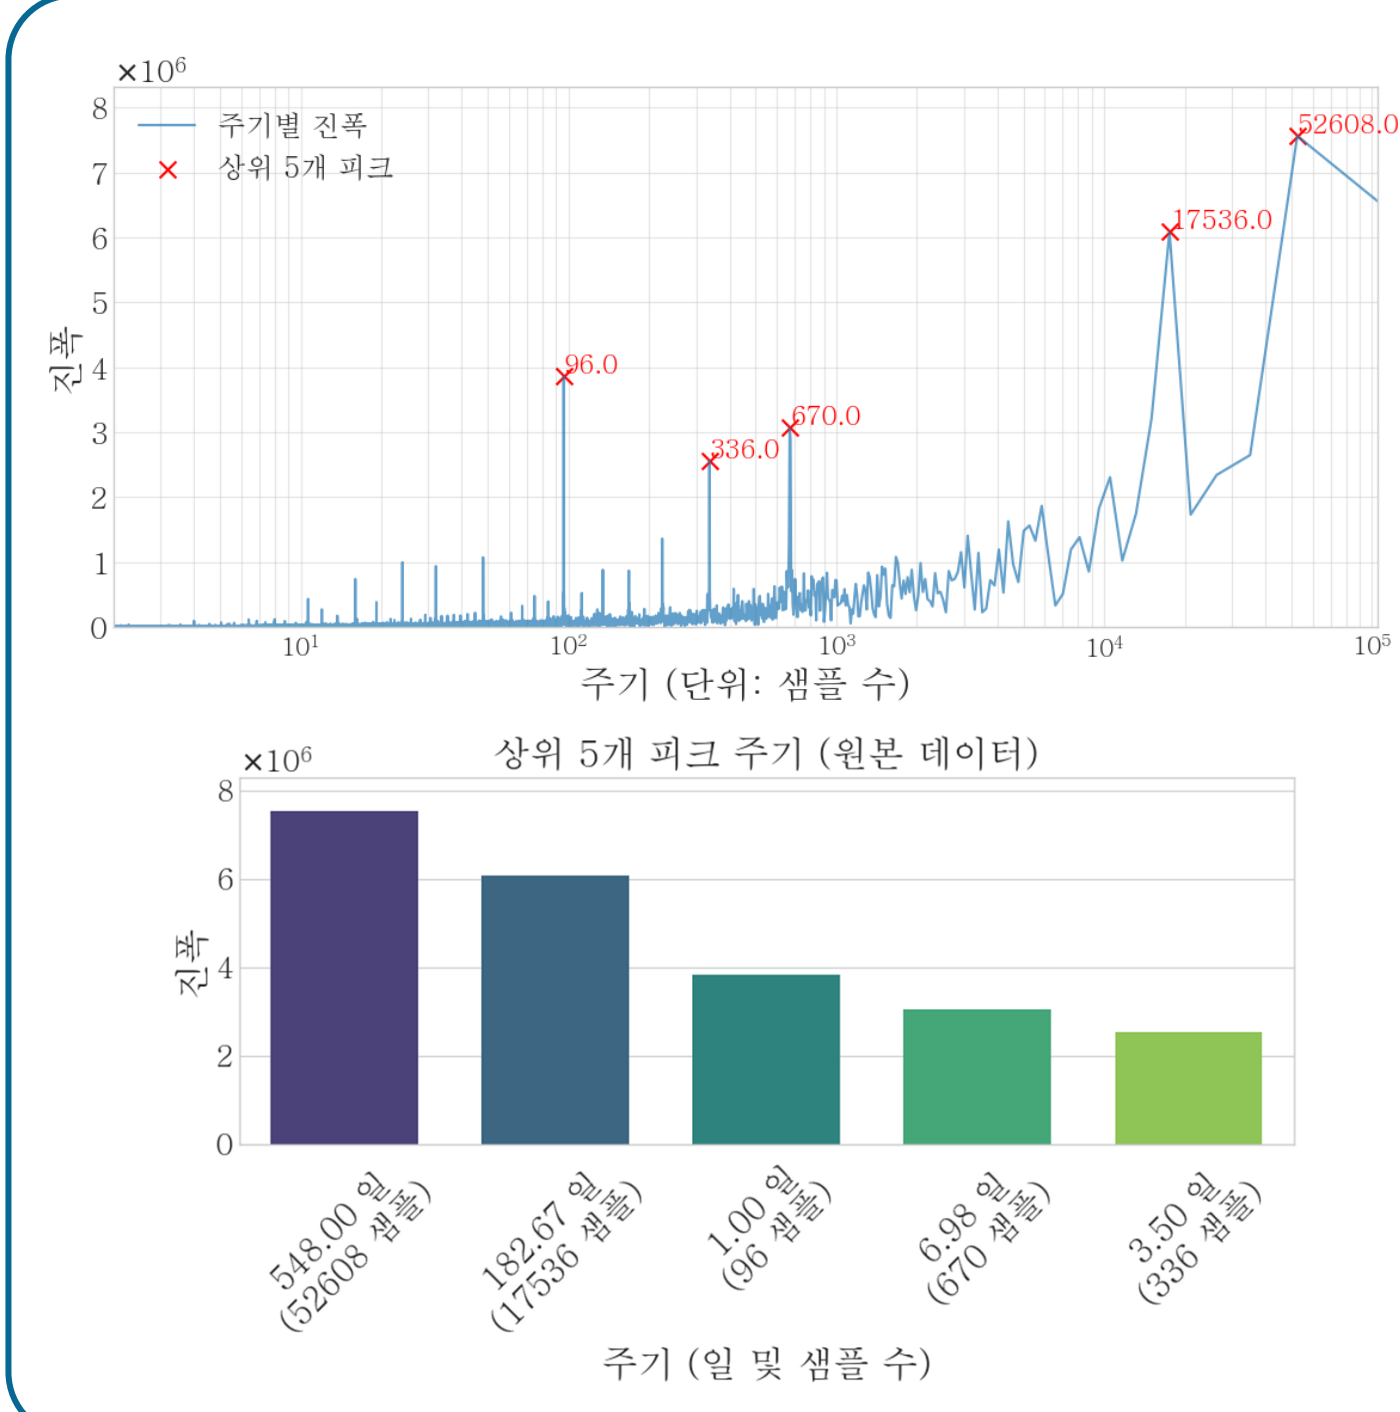


그림 2. 원본 데이터의 FFT 분석 및 피크 식별 결과




그림 3. 1차 차분 데이터의 FFT 분석 및 피크 식별 결과

### GELU CNN-GRU Autoencoder 모델

- CNN 계층으로 윈도우 내 지역적 패턴을 추출
- GRU 계층이 시계열의 시간적 의존성을 학습하여 저차원 잠재 벡터로 압축 후 다시 원본 차원으로 복원하는 구조

→ GELU 활성화 함수를 적용하여 학습 안정성 및 성능을 향상

구분	항목명	값 또는 설명
입력	입력 차원	1 (단변량 시계열)
	층의 개수	32
	커널 크기	7
	Stride	윈도우 크기의 25%
CNN 구조	활성화 함수	GELU
	Dropout 비율	0.1
GRU 구조	문맥 차원	64
	GRU 계층 수	1
잠재 공간	차원	32
학습 설정	Epochs	50
	Batch Size	128
	Learning Rate	0.0001
	Optimizer	Adam
손실 함수	손실 함수	평균 제곱근 오차 (RMSE Loss)

표1. GELU CNN-GRU AE 모델 주요 파라미터

### DTW 재구성 오차 기반 IsolationForest 이상치 탐지




그림5. (윈도우 크기 96) DTW 재구성 오차 분포

- 모델이 재구성한 윈도우와 원본 윈도우 간의 형태적 유사성을 시간 축 왜곡에 강인한 DTW(Dynamic Time Warping)로 계산하여 재구성 오차를 산출

- 이 오차 분포에 비지도 학습인 Isolation Forest를 적용하여 이상치 윈도우를 최종 판별

## Results & Discussion

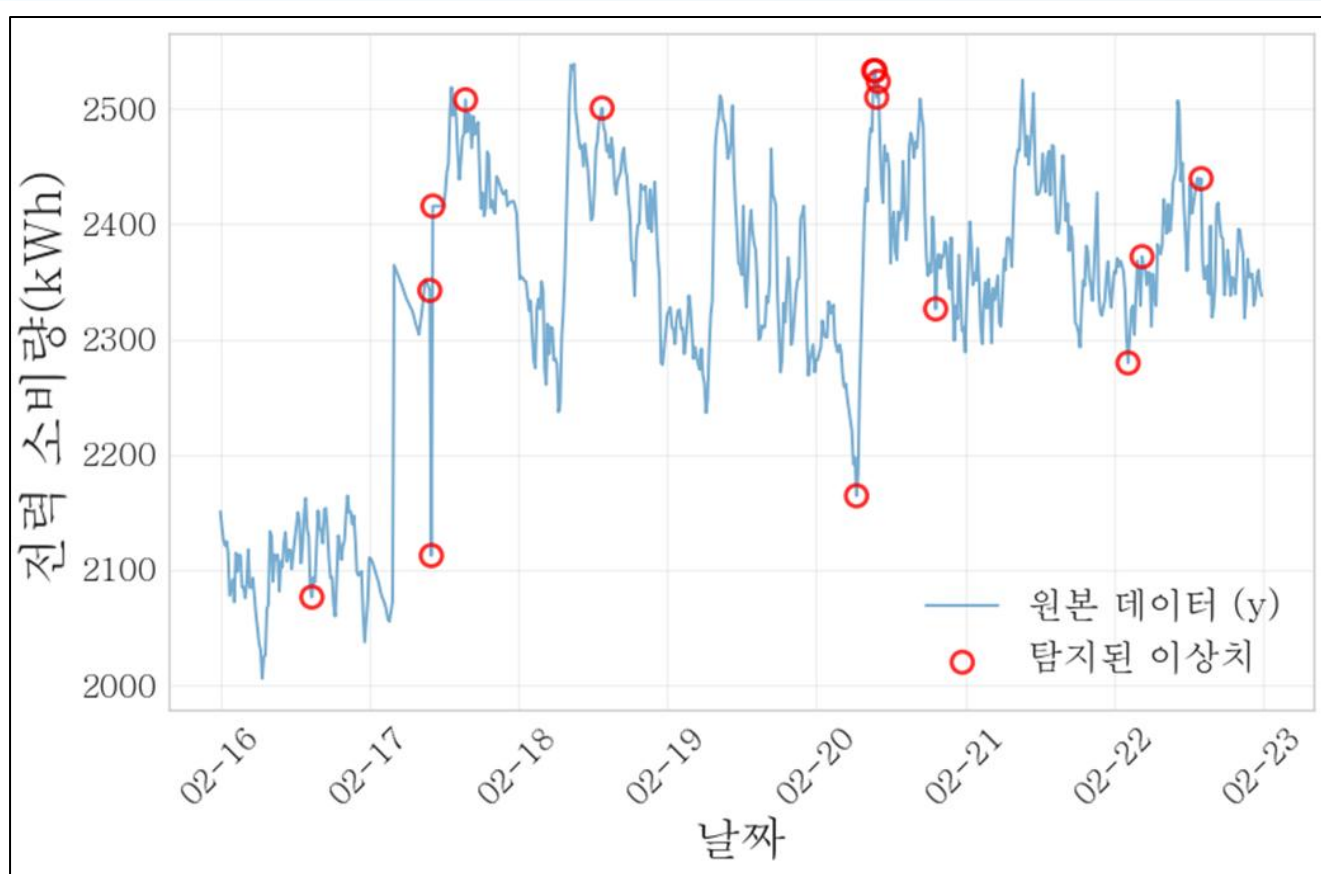


그림 5. (2020년 2월 16일 ~ 2020년 2월 22일)의 이상치 검출 결과

- 다중 스케일 이상치 탐지: FFT 기반 데이터 특성에 맞는 다중 윈도우 설정으로, 순간적인 피크나 강하 같은 단기 이상과 미묘한 패턴 변화를 보이는 장기 이상을 모두 효과적으로 탐지
- 강건한 탐지 성능: DTW 오차와 Isolation Forest의 결합을 통해 단순한 값의 변동뿐 아니라, 시간적 왜곡이 포함된 복잡한 형태의 이상 패턴까지 정밀하게 식별

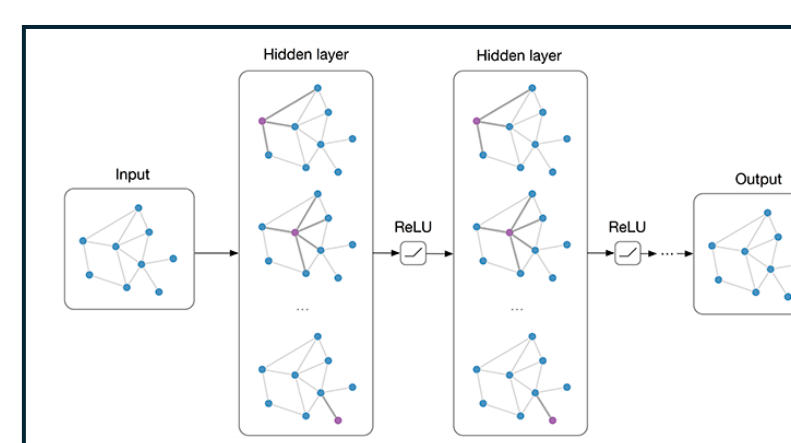
- 실제 산업 이상 상황 매핑: 탐지된 이상치들은 실제 현장의 설비 가동 중단, 예기치 않은 부하 발생, 공정 라인 비정상 가동 등 다양한 잠재적 위험 상황과 연결 가능

## Future Works

- (정밀 이상 탐지) 본 연구는 1차 차분, FFT 기반 주기 분석, GELU-CNN-GRU Autoencoder, DTW, Isolation Forest의 다단계 결합으로 산업 전력 데이터의 다양한 이상 패턴을 효과적으로 탐지할 수 있음을 실증함
- (확장성) 향후 모델의 지속적인 발전을 통해 보다 다양한 산업 데이터셋으로 확장 및 이상 원인 분석, 실시간 예측 모델과의 연동을 통하여 자동화 · 고도화 추진 예정
- (스마트 팩토리 적용) 제안된 방법론은 스마트 팩토리 실시간 모니터링, 에너지 효율 관리 및 설비 예지보전을 통해 산업 현장에서의 실질적 기여를 기대함

### (향후 모델 개선 방안)

CNN 레이어를 GCN으로 구성하여 모델 훈련



- 더 강력한 시계열 데이터 반응
- 데이터 간 관계에 더 집중
- 미래 예측력이 더 강한 BILSTM 네트워크에 접목 가능

그림. GCN 연결 노드